


2. TINJAUAN PUSTAKA

Pada bab ini dijelaskan mengenai semua teori yang digunakan untuk pengerjaan skripsi ini. Semua teori ini membantu pengerjaan skripsi ini dari awal sampai selesai.

2.1 Recurrent Neural Network (RNN)

Recurrent Neural Network (RNN) adalah kasus khusus dari *neural network* dengan tujuan untuk memprediksi langkah selanjutnya berdasarkan langkah sebelumnya. RNN disebut “Recurrent” karena melakukan tugas yang sama pada setiap elemen dengan karakteristik memanfaatkan informasi yang ditangkap sebelumnya. Struktur RNN terdiri dari *input layer*, satu atau lebih *hidden layer* dan *output layer*. RNN memiliki struktur seperti rantai pengulangan modul sebagai memori untuk menyimpan informasi dari langkah-langkah pemrosesan sebelumnya. Tidak seperti *feedforward neural network*, RNN menyertakan sebuah *feedback loop* yang memungkinkan jaringan saraf menerima urutan *input*. *Output* dari langkah $t-1$ diteruskan ke jaringan untuk mempengaruhi *output* langkah t dan untuk setiap langkah berikutnya (Le et al, 2019). Gambar 2.1 menunjukkan proses *sequential* pada RNN.



Gambar 2.1 Proses *Sequential* pada Recurrent Neural Network (RNN) (Le et al, 2019)


Gambar 2.1 menggambarkan RNN secara sederhana dengan satu unit *input*, satu unit *output* dan satu unit *recurrent hidden* yang diperluas menjadi *full network*, dimana x_t adalah *input* pada langkah waktu t dan h_t adalah *output* pada langkah waktu t (Le et al, 2019).

2.2 Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) adalah jenis arsitektur RNN yang membantu dalam melatih model dalam urutan yang panjang dan dalam retensi memori dari langkah-langkah waktu sebelumnya dari *input* yang dimasukkan ke model. LSTM memecahkan masalah menghilang atau meledaknya gradien dengan memperkenalkan *additional gate*, *input gate* dan

forget gate yang memungkinkan kontrol yang lebih baik atas gradien, dengan mengizinkan informasi apa yang harus disimpan dan apa yang harus dilupakan, sehingga mengontrol akses informasi ke keadaan sel saat ini (Goyal et al, 2018).

LSTM juga memiliki struktur *chainlike* tetapi pada modul yang diulang mempunyai struktur yang berbeda. LSTM dibentuk dengan menggunakan *multiple gates* yang berfungsi sebagai opsi yang baik untuk mengatur informasi yang masuk. *Multiple gates* memiliki lapisan *sigmoid neural network* dimana *output* pada $[0,1]$ untuk memberikan batasan minimal dari komponen dan sebuah operasi *point-wise multiplication* (Goyal et al, 2018).



Gambar 2.2 Modul LSTM dengan 4 lapisan yang saling berinteraksi (Goyal et al, 2018)

Pada Gambar 2.2 c_t adalah *cell state* yang menggambarkan setiap langkah waktu dan diubah oleh interaksi pada setiap langkah waktu. Untuk menjaga informasi tetap mengalir pada LSTM melalui *cell state*, terdapat tiga tipe *gate* (Goyal et al, 2018).


Input gate merupakan *gate* jenis pertama untuk mengontrol kontribusi dari *input* yang baru ke dalam memori.

$$i_t = \sigma (W_i \cdot [h_{t-1}, X_t] + b_i) \quad (2.1)$$

$$\hat{c}_t = \tanh(W_c \cdot [h_{t-1}, X_t] + b_c) \quad (2.2)$$

Pada Rumus 2.1 dan Rumus 2.2 X_t melambangkan *input* pada langkah waktu t , h_{t-1} melambangkan *hidden state* pada langkah waktu $t - 1$, i_t melambangkan *input gate layer output* pada langkah waktu t , c_t menandakan nilai kandidat yang akan di tambahkan dengan *input gate output* pada langkah waktu t , b_i dan b_c melambangkan bias dari *input gate layer* dan bias perhitungan nilai kandidat, W_i dan W_c melambangkan beban dari *input gate layer* dan

beban perhitungan nilai kandidat (Goyal et al, 2018). Gambar 2.3 menggambarkan contoh *input gate* dari modul LSTM pada Gambar 2.2.




Gambar 2.3 Bagian *Input Gate* dari Modul LSTM (Goyal et al, 2018)

Gate selanjutnya yaitu *forget gate* yang berfungsi untuk mengontrol batas nilai yang terkait pada memori.

$$f_t = \sigma(W_f \cdot [h_{t-1}, X_t] + b_f) \quad (2.3)$$

Pada Rumus 2.3 f_t melambangkan *forget state* pada langkah waktu t , W_f dan b_f melambangkan beban dan bias dari *forget state* pada langkah waktu t (Goyal et al, 2018). Gambar 2.4 menggambarkan contoh *forget gate* dari modul LSTM pada Gambar 2.2.




Gambar 2.4 Bagian *Forget Gate* dari Modul LSTM (Goyal et al, 2018)

Gate yang terakhir adalah *output gate* yang berfungsi untuk mengontrol batas memori berkontribusi dalam blok aktivasi *output*.

$$o_t = \sigma(W_o \cdot [h_{t-1}, X_t] + b_o) \quad (2.4)$$

$$h_t = o_t * \tanh(C_t) \quad (2.5)$$

Pada Rumus 2.4 dan 2.5, O_t melambangkan *output gate* pada langkah waktu t , W_o dan b_o melambangkan beban dan bias dari *output gate* pada langkah waktu t (Goyal et al, 2018). Gambar 3.8 menggambarkan contoh *output gate* dari modul LSTM pada Gambar 2.2.



Gambar 2.5 Bagian *Output Gate* dari Modul LSTM (Goyal et al, 2018)

2.3 Autoregressive Integrated Moving Average (ARIMA)

Autoregressive Integrated Moving Average (ARIMA) adalah model dari sebuah kelas yang menjelaskan deret waktu tertentu berdasarkan nilai masa lalu. Persamaan yang diturunkan oleh ARIMA dapat digunakan untuk meramalkan nilai-nilai yang akan datang. Secara teoritis, setiap *time series nonseasonal* yang menunjukkan pola dan tidak beracak dapat dimodelkan dengan ARIMA. Model ARIMA dapat diklasifikasikan sebagai (p,d,q) model dimana p adalah jumlah suku *autoregressive* (AR), q adalah jumlah suku rata-rata bergerak (MA) dalam persamaan prediksi, dan d adalah urutan perbedaan yang diperlukan untuk *stasioneritas*. Rumus untuk menghitung ARIMA adalah sebagai berikut (Sun. J, 2021):

$$y_t = C + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \dots - \theta_q \varepsilon_{t-q} \quad (2.6)$$

Keterangan :

y_t = nilai peramalan

C = konstanta

$\phi_1, \phi_2, \dots, \phi_p$ = parameter model *autoregressive*

$\theta_1, \theta_2, \dots, \theta_q$ = parameter model *moving average*

p = celah antara t dan $t - p$

q = celah antara t dan $t - q$

2.4 Holt-Winters Exponential Smoothing

Metode *time series* biasanya digunakan pada data yang menunjukkan tren atau pola musiman dengan prediksi yang dihasilkan menjadi rata-rata penimbangan dari pengamatan masa lalu dengan bobot yang menurun secara eksponensial sebagai pengamatan. Ada 3 bagian dari *exponential smoothing* yaitu *single*, *double*, dan *triple* yang biasa diketahui dengan *Holt-Winters* model. *Holt-Winters* model berguna menangkap komponen dan musiman tren untuk menghasilkan *time series* yang di *smoothing*. Rumus untuk menghitung *Holt-Winters* adalah sebagai berikut (Kawamukai & Omar, 2021):

$$\text{Level, } l_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(l_{t-1} + b_{t-1}) \quad (2.7)$$

$$\text{Trend, } b_t = \beta^*(l_t - l_{t-1}) + (1 - \beta^*) b_{t-1} \quad (2.8)$$

$$\text{Seasonal, } s_t = \gamma(y_t - l_{t-1} - b_{t-1}) + (1 - \gamma)S_{t-m} \quad (2.9)$$

$$\text{Forecast, } \hat{y}_{t+h|t} = l_t + hb_t + S_{t+h-m(k+1)} \quad (2.10)$$

Keterangan:

α = koefisien *smoothing* berdasarkan level

β = koefisien *smoothing* berdasarkan tren

γ = koefisien *smoothing* berdasarkan *seasonality*

k = integer dari $(h - 1)/m$

m = frekuensi dari *seasonality*

t = waktu

$(y_t - S_{t-m})$ = pengamatan yang disesuaikan secara musiman

$(l_{t-1} + b_{t-1})$ = prakiraan non-musiman

$(y_t - l_{t-1} - b_{t-1})$ = indeks musiman saat ini

2.5 Root Mean Square Error (RMSE)

Root Mean Square Error (RMSE) adalah ukuran yang sering digunakan untuk menilai akurasi prediksi yang diperoleh model. Ini mengukur perbedaan atau residu antara nilai aktual dan nilai prediksi. Metrik ini membandingkan kesalahan prediksi model yang berbeda untuk data

tertentu, bukan antar kumpulan data. Rumus untuk menghitung RMSE adalah sebagai berikut (Siarni-Namini et al, 2018):

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2} \quad (2.11)$$

Dimana N adalah jumlah total pengamatan, x_i adalah nilai sebenarnya, sedangkan, $\hat{x}_i$ adalah nilai prediksi. Manfaat utama menggunakan RMSE adalah dapat menangani *large error* dan juga menskalakan nilai RMSE dalam unit yang sama dengan nilai perkiraan. Ketiga penelitian sejenis pada tinjauan studi menggunakan RMSE sebagai metrik untuk mengukur akurasi model LSTM.

2.6 Mean Absolute Percentage Error (MAPE)

Dalam penelitian ini digunakan juga *Mean Absolute Percentage Error* (MAPE) untuk mengukur tingkat akurasi hasil peramalan penjualan motor. Metrik ini dipilih karena dalam mengukur akurasi mempunyai kriteria nilai yang jelas. Ada pula rumus MAPE sebagai berikut (Kim & Kim, 2016):

$$M = \frac{1}{n} \sum_{t=1}^n \left| \frac{A_t - F_t}{A_t} \right| \quad (2.12)$$

Keterangan:

M = *Mean Absolute Percentage Error* (MAPE)

n = banyaknya data

A_t = nilai sebenarnya

F_t = nilai prediksi

MAPE adalah rata-rata dari persentase error absolut (Kim & Kim, 2016). Semakin kecil nilai MAPE berarti nilai prediksi semakin mendekati nilai sebenarnya. Kriteria nilai MAPE ditunjukkan pada tabel sebagai berikut (Gustriansyah et al., 2017):

Tabel 2.1

Nilai MAPE

Nilai MAPE	Kriteria
<10%	Sangat Baik

10-20%	Baik
20-50%	Cukup Baik
>50%	Buruk

Sumber: Gustriansyah, R., Sensuse, D., & Ramadhan, A. (2017). A Sales Prediction Model Adopted the Recency-Frequency-Monetary Concept. Indonesian Journal Of Electrical Engineering And Computer Science, 6(3), 711-720.

2.7 Tinjauan Studi

2.7.1 A Comparison of ARIMA and LSTM in Forecasting Time Series

- Masalah

Prediksi data *time series* menjadi sebuah tantangan terutama karena perubahan tren ekonomi yang belum pernah terjadi sebelumnya dan di satu sisi memiliki syarat-syarat, di sisi lain informasi tidak lengkap. Volatilitas pasar dalam beberapa tahun terakhir perlu ditanggapi dengan serius untuk peramalan *time series* ekonomi dan keuangan. Oleh karena itu, menilai keakuratan peramalan diperlukan ketika menggunakan berbagai metode peramalan. Tujuan utama dari penelitian ini untuk menyelidiki metode peramalan dengan kesalahan perkiraan yang lebih rendah dan akurasi perkiraan yang lebih tinggi. Pada penelitian ini membandingkan model ARIMA dan LSTM.

- Metode

Algoritma pertama yang digunakan adalah ARIMA. Tahap awal yaitu membagi *data set* menjadi dua *subset* dimana 70% *training set* dan 30% *test set*. Tahap kedua yaitu menentukan notasi ARIMA(p,d,q). Penelitian ini menggunakan ARIMA(5,1,0) untuk memodelkan *test data*. Selanjutnya algoritma melakukan peramalan, hasil nilai peramalan ditambahkan ke struktur data prediksi, kemudian nilai sebenarnya ditambahkan ke *test set* untuk menyempurnakan dan memperbaiki model. Akhirnya, setelah membangun struktur data prediksi, algoritma menghitung nilai RMSE untuk mengukur akurasi prediksi.

Algoritma kedua yang digunakan yaitu LSTM. Tahap pertama yaitu membagi *data set* menjadi 70% *training set* dan 30% *test set*. Tahap selanjutnya yaitu menentukan *random number seed*, penelitian ini menetapkan *seed number* 7. Kemudian algoritma mendefinisikan fungsi "*fit lstm*" yang melatih dan membangun model LSTM. *Function*

mengambil *training data set*, jumlah *epoch* dan jumlah neuron. Selanjutnya model membuat *hidden layer* dan menyusun model, *loss function* dan optimisasi algoritma menggunakan “*mean squared error*” dan “ADAM”. Setelah kompilasi dilakukan penyesuaian model dengan *training data set*. Jumlah *epoch* dan neuron ditentukan menjadi 1 dan 4. Selanjutnya LSTM model diberikan *training data set*, jumlah *epoch* dan jumlah neuron. Kemudian dilakukan prediksi terhadap *test data*. Tahap terakhir yaitu menghitung RMSE dari LSTM model.

- Hasil

Data keuangan *time series* menunjukkan rata-rata RMSE menggunakan model Rolling ARIMA dan Rolling LSTM masing-masing adalah 511.481 dan 64.213 dan menghasilkan rata-rata 87.445 pengurangan tingkat kesalahan oleh LSTM. Data ekonomi menunjukkan rata-rata RMSE untuk Rolling ARIMA dan Rolling LSTM adalah 5.999 dan 0.936 dan menghasilkan rata-rata 84.394 pengurangan tingkat kesalahan oleh LSTM.

2.7.2 Application of Long Short-Term Memory (LSTM) Neural Network for Flood Forecasting

- Masalah

Banjir merupakan penyebab kerugian sosial dan ekonomi yang signifikan, bahkan dapat merenggut nyawa manusia. Hal ini menimbulkan potensi bahaya bagi daerah pada penduduk yang terletak di sebelah hilir sungai-sungai besar. Prakiraan aliran banjir yang akurat merupakan persyaratan penting untuk mengurangi risiko banjir dan perencanaan serta pengelolaan sistem sumber daya air. Namun, peramalan yang akurat adalah masalah yang sulit karena analisa banjir adalah proses dinamis yang kompleks dengan variasi spasial dan temporal. Selain itu, aliran sungai bersifat *non linear* dan dipengaruhi oleh banyak faktor seperti permukaan cekungan sungai, curah hujan serta medan dasar sungai dan karakteristik iklim. Dalam penelitian ini digunakan beberapa model LSTM untuk peamalan debit pada *Da River*, salah satu sungai terbesar di Vietnam.

- Metode

Pada penelitian ini, penulis membagi ke dalam dua skenario. Skenario pertama menggunakan *input* data curah hujan dan debit yang diukur pada sebelas stasiun pengukur hulu dan data laju aliran sungai pada stasiun Hoa Binh. Dalam skenario kedua, *input* data terdiri dari data debit yang diamati pada lima stasiun hidrologi, empat stasiun

hulu dan stasiun *Hoa Binh*. Yang membedakan kedua skenario hanya terletak pada *input* data, penelitian melanjutkan ke tahap selanjutnya yang sama. Tahap pertama penulis membagi data menjadi tiga set yaitu *training*, *validation* dan *testing*. Kemudian penulis menentukan *learning rate* sebesar 0.0001, jumlah maksimum *epoch* 100.000 dan jumlah unit 20,30,50. Dari ketiga hal tersebut dapat dilakukan prediksi terhadap *training data* dengan model LSTM. Tahap akhir yang itu menghitung nilai RMSE dan NSE.

- Hasil

Perbedaan antara nilai *relative error* dalam prakiraan banjir dari dua skenario berkisar dari 1,5% hingga 3,5%, dengan hasil prediksi yang sangat akurat termasuk dalam skenario kedua. Skenario kedua cenderung meramalkan nilai aliran terbesar lebih baik dari yang pertama, karena terkadang dengan adanya data curah hujan dapat mengakibatkan perkiraan aliran menjadi kurang akurat. Dari hasil analisis membuktikan keunggulan luar biasa dari model LSTM dalam kemampuannya untuk mempelajari dependensi singkat secara efektif, dan model ini dapat sepenuhnya diterapkan untuk memperkirakan aliran sungai dua hari atau bahkan tiga hari ke depan dengan akurasi lebih dari 86%.

2.7.3 Short-Term Load Forecasts Using LSTM Networks

- Masalah

Dengan meningkatnya kebutuhan beban dan kecanggihan pembangkit listrik, mengetahui terlebih dahulu tentang beban listrik tidak hanya pada periode jangka pendek seperti jam atau beberapa hari tetapi juga selama periode jangka panjang seperti minggu dan bulan sangat diperlukan untuk berbagai manfaat seperti dampak teknis dan ekonomi yang penting. Analisis dan pengelolaan beberapa tugas seperti pembelian/penjualan pasar, perencanaan pemadaman sehari sebelumnya, Unit Commitment(UC) dan pengiriman ekonomi, manajemen penyimpanan energi, kontrak energi masa depan, jadwal pemeliharaan pembangkit listrik, dan penataan portofolio memerlukan fakta mengetahui tentang permintaan yang akan datang dan kebutuhan beban. Pada penelitian ini bertujuan untuk menggunakan metode tradisional dan LSTM dengan konsep untuk menganalisis data beban listrik dan menemukan pendekatan terbaik untuk mencapai perkiraan beban listrik yang lebih baik.

- Metode

Data terbagi menjadi dua bagian yaitu data 12 bulan digunakan untuk tujuan *training/modelling* dan data bulan ke-13 digunakan untuk validasi peramalan. Untuk model lain seperti ARMA, SARIMA, dan ARMAX, level pemrosesan data DS5 digunakan. Dalam penelitian ini menggunakan LSTM *toolbox* pada Matlab2018 untuk melatih *network*. Langkah awal yaitu dengan menentukan spesifikasi *layer* seperti *input* TSs, *output* TSs, jumlah *hidden LSTM units*, *solver*, jumlah iterasi *training (max epochs)*, inisial *learn rate*, *gradient threshold*. Setelah spesifikasi tersebut ditentukan, model LSTM dapat dilatih dan melakukan peramalan.

- Hasil

Nilai MAPE untuk peramalan 24 jam dengan ARMA sebesar 5.42, SARIMA sebesar 6.53, ARMAX sebesar 7.51, LSTM sebesar 1.5222. Jika dibandingkan dengan ketiga model lainnya, LSTM memiliki nilai MAPE terkecil. Dapat disimpulkan bahwa peramalan dengan LSTM *network* terbaik dari ketiga model lainnya. Nilai MAPE LSTM untuk perkiraan 48 jam 2.16, 7 hari 5.97, 20 hari 9.75. Pola MAPE untuk LSTM terus meningkat seiring bertambahnya jumlah jam prakiraan.

2.7.4 Prediction Of NDVI Using The Holt-Winters Model In High And Low Vegetation Regions: A Case Study Of East Africa

- Masalah

Vegetation adalah salah satu sumber daya utama yang memainkan peran utama dalam pencegahan kekeringan tanah dan air. Wilayah Afrika Timur memiliki berbagai jenis vegetasi mulai dari hutan hingga padang rumput, namun rentan terhadap *degradation vegetation* akibat dari peningkatan populasi manusia, permintaan lahan pertanian dan perubahan iklim secara global. Karakterisasi pola *spatial* dan *temporal vegetation* sangat penting untuk menilai kondisi secara *landscape* dan memprediksi model permukaan tanah. NDVI banyak digunakan untuk melihat *vegetation* serta studi mengenai *vegetation* untuk periode dan area tertentu. Dengan demikian data NDVI dapat memberikan informasi mengenai perubahan pada *vegetation*, namun penerapan metode tersebut dalam peramalan *vegetation* masih kurang dieksplorasi lebih lanjut. Oleh karena itu dalam penelitian ini akan melakukan *forecasting* NDVI.

- Metode

Pada tahap awal data yang di download yaitu data MOD13Q1. Setelah itu dilakukan NDVI *data extraction* yang mengambil pixel data NDVI. Selanjutnya akan dilakukan *preprocessing data* seperti membuat NDVI time series untuk setiap bulannya, menggunakan *scale factor* untuk melakukan normalisasi rata – rata nilai NDVI tiap bulan. Membagi data *training* sebesar 188 bulan (Februari 2000 – September 2015) dan *data testing* sebesar 48 bulan (Oktober 2015 hingga September 2019). Tahap berikutnya menerapkan *Holt – Winters model* dan melakukan perhitungan terhadap hasil model menggunakan RMSE dan MAE. Selanjutnya akan dilakukan Visualisasi *spatial maps* untuk jangka waktu 6 bulan dan tahapan terakhir yaitu melakukan validasi terhadap hasil forecast dalam bentuk RMSE, MAE, dan MAPE.

- Hasil

Dari hasil *time series analysis* didapatkan rata – rata nilai NDVI antara 0.2 hingga 0.6 tergantung dari periode beserta kesehatan dari *vegetation*. Sedangkan untuk daerah yang memiliki *vegetation* yang bagus memiliki rata – rata nilai NDVI sekitar 0.3 hingga 0.8. Nilai rata – rata dari periode pembelajaran yaitu sekitar 0.5, selain itu didapatkan nilai MAE dan RMSE sebesar 0.00679 dan 0.084 secara berurutan.

Tabel 2.2

Tinjauan Studi

Nama Peneliti	Tahun	Masalah	Metode	Hasil
Siemi-Namini, et al.	2018	Perubahan tren ekonomi yang belum pernah terjadi sebelumnya	ARIMA dan LSTM	RMSE ARIMA 511.481 dan LSTM 64.213 untuk data keuangan time series. RMSE ARIMA 5.999 dan LSTM 0.936 untuk data ekonomi
Le, et al.	2019	Banjir merupakan penyebab kerugian sosial dan ekonomi yang signifikan, bahkan	LSTM	Akurasi lebih dari 86% untuk memperkirakan aliran sungai dua hari

		dapat merenggut nyawa manusia.		atau bahkan tiga hari ke depan
Muzaffar & Afshari	2019	Meningkatnya kebutuhan beban dan kecanggihan pembangkit listrik	ARMA, SARIMA, ARMAX, LSTM	MAPE peramalan 24 jam ARMA 5.42, SARIMA 6.53, ARMAX 7.51, LSTM 1.5222
Omar & Kawamukai	2021	Kurangnya eksplorasi mengenai peramalan vegetation menggunakan NDVI	Holt – Winters	Rata – rata nilai NDVI sebesar 0.5 serta nilai MAE dan RMSE sebesar 0.0679 dan 0.084