

2. LANDASAN TEORI

2.1 Tinjauan Pustaka

Pada bagian ini, teori-teori yang akan digunakan dalam penulisan skripsi maupun pembuatan sistem akan dijabarkan.

2.1.1 Prediksi

Prediksi atau biasa juga disebut *forecasting* adalah sebuah kegiatan memperkirakan atau memprediksi suatu informasi di masa depan dengan harapan dapat mengambil keputusan yang tepat pada masa kini. *Forecasting* biasanya erat kaitannya dengan kegiatan bisnis dan biasa digunakan untuk menentukan jumlah produksi, *budget* perusahaan, pembelian dari *supplier*, dan lain-lain (PDAI Universitas Medan Area, 2022). Menurut Populix (2023), beberapa contoh penerapan *forecasting* di perusahaan adalah sebagai berikut:

1. Meramalkan bagaimana suatu proyek akan diterima di pasar kedepannya
2. Sebagai sarana untuk memperkirakan batasan dana yang akan dikeluarkan oleh perusahaan
3. Memperkirakan potensi dan risiko di masa depan untuk bisa mengambil kebijakan di masa kini
4. Meningkatkan ketepatan atas keputusan yang akan diambil oleh perusahaan karena *forecasting* didasarkan dari data perusahaan itu sendiri di masa lampau

Menurut Maulida (2011), ada beberapa jenis *forecasting* yang bisa dilakukan oleh suatu perusahaan / organisasi:

1. *Forecasting* berdasarkan waktu
Terdiri dari jangka panjang, menengah, dan pendek. *Forecasting* jangka panjang bisa mencapai kurun waktu 2 tahun atau lebih sementara *forecasting* jangka pendek biasanya hanya sekitar 0-3 bulan di masa depan.
2. *Forecasting* berdasarkan fungsi dan tujuan
Ada banyak fungsi dan tujuan *forecasting* dimana biasanya diklasifikasikan menjadi 4 yaitu bisnis umum, penjualan, permintaan, dan keuangan. Bisnis umum biasanya meramalkan keseluruhan bisnis, penjualan meramalkan penjualan di masa depan, permintaan meramalkan perkiraan permintaan pasar, dan keuangan meramalkan biaya yang dibutuhkan di masa depan.
3. *Forecasting* berdasarkan ketersediaan data

Forecasting ini didasarkan pada dataset yang didapatkan, biasanya dibedakan menjadi 2 yaitu metode kualitatif dan kuantitatif. Metode kualitatif misalnya metode delphi (para ahli berkumpul untuk berpendapat), riset pasar, konsensus, analogi sejarah, dan personal insight. Sementara metode kuantitatif misalnya adalah metode time series yang membandingkan antara variabel yang diramalkan dengan waktu, serta metode kausal yaitu metode yang berbasis pada sebab-akibat dimana satu atau lebih variabel independen akan mempengaruhi pergerakan suatu variabel. Metode kausal sendiri memiliki 3 pendekatan yaitu regresi dan korelasi, ekonometrik, dan input-output.

2.1.2 Performa Perkuliahan

Menurut Kamus Besar Bahasa Indonesia (KBBI), performa adalah hal melakukan, hal menyelenggarakan, hal memainkan, atau penampilan (Setiawan, n.d.). Karena itu, performa perkuliahan bisa mengacu pada penampilan, hasil, dan kualitas pencapaian seorang mahasiswa selama mengikuti pendidikan di perguruan tinggi. Performa ini mencerminkan sejauh mana mahasiswa mampu menggunakan keterampilan, pengetahuan, dan kompetensinya untuk mencapai hasil yang diharapkan dalam tugas-tugas perkuliahan (Tasim, 2024). Dalam konteks akademik, performa perkuliahan dapat diartikan sebagai kesuksesan belajar atau prestasi belajar (Lestari, 2019).

Performa perkuliahan merupakan faktor yang sangat penting mengingat kuliah sendiri juga memegang peranan yang cukup penting di hidup. Menurut Prastiwi & Ihsan (2021) melalui kompas.com, berikut adalah beberapa alasan mengapa kuliah itu penting:

1. Menjadi sarana untuk meningkatkan pengetahuan dan keterampilan
2. Memudahkan dalam mendapatkan pekerjaan yang diinginkan
3. Bisa menjadi standar pendidikan terendah
4. Bisa membantu dalam membangun pola pikir yang lebih dewasa
5. Memperluas jaringan relasi dan pertemanan
6. Menjadi langkah pertama untuk merubah hidup
7. Bisa menjadi sarana untuk mendapatkan banyak pengalaman baru

Performa perkuliahan bisa dilihat melalui Indeks Prestasi Kumulatif (IPK) dari mahasiswa tersebut yang memperlihatkan performa akademis mahasiswa tersebut. IPK sendiri adalah angka / nilai yang menjadi ukuran prestasi seorang mahasiswa saat belajar di bangku perkuliahan mulai dari awal hingga akhir (“Indeks Prestasi”, n.d.). Selain IPK, juga ada faktor lain yang bisa disebut sebagai performa perkuliahan yaitu keaktifan

berorganisasi dan kegiatan sosial yang memperlihatkan performa sosial mahasiswa tersebut. Performa sosial juga penting dalam performa perkuliahan mengingat beberapa penelitian menyatakan keaktifan berorganisasi memiliki pengaruh dalam pencapaian akademis seseorang (Alexandro, Putri, & Hariatama, 2022).

2.1.3 *Correlation Matrix*

Correlation Matrix adalah sebuah matriks yang menunjukkan hubungan antar variabel. Melalui *correlation matrix*, hubungan antar variabel bisa terlihat, misalnya memiliki variabel A sangat mempengaruhi variabel B secara positif, atau variabel A sedikit mempengaruhi variabel B secara negatif. *Correlation matrix* bisa sangat berguna untuk teknik-teknik regresi seperti *linear regression*, *multiple linear regression*, dan *lasso regression*, karena pada regresi beberapa variabel independen akan digunakan untuk memprediksi variabel dependen sehingga sangat penting diketahui hubungan antara keduanya terlebih dahulu (Wagavkar, 2023). Pada dasarnya, *correlation matrix* berbentuk kotak dengan variabel yang sama mengisi judul baris dan kolom. Di tengah baris dan kolom akan terdapat angka yang menunjukkan hubungan antara variabel yang ada di baris dan variabel yang ada di kolom tersebut (Bock, 2018).

Berikut adalah langkah untuk menghitung *correlation matrix* antara variabel X dan Y:

1. Mencari hasil perkalian dari X dan Y (diwakili dengan variabel XY)
2. Mencari hasil dari X² dan Y² untuk setiap value variabel
3. Menghitung sigma (Σ) dibagi total untuk setiap kolom
4. Menghitung r (koefisien) menggunakan rumus korelasi koefisien Pearson

$$r = \frac{n(xy) - (x)(y)[nx^2 - (x)^2][ny^2 - (y)^2]}{n^2} \quad (2.1)$$

Jika menggunakan bahasa pemrograman python, *correlation matrix* bisa dengan menggunakan *library* pandas, dimana data yang ingin di cek diubah ke Data Frame terlebih dahulu sebelum memanggil metode `corr()`. Untuk interpretasi dari hasil *correlation matrix*, terdapat 3 jenis korelasi yang mungkin dihasilkan yaitu:

1. Korelasi positif
Korelasi positif berarti semakin tinggi X, semakin tinggi pula Y yang akan diprediksi. Korelasi ini terjadi saat hasil koefisien menunjukkan angka lebih besar dari 0.
2. Tidak ada korelasi
Tidak ada korelasi berarti tidak ada korelasi sama sekali antara X dan Y.. Korelasi ini terjadi saat hasil koefisien menunjukkan angka sama dengan 0.

3. Korelasi negatif

Korelasi negatif berarti semakin tinggi X, semakin kecil Y yang akan diprediksi. Korelasi ini terjadi saat hasil koefisien menunjukkan angka lebih kecil dari 0.

Correlation matrix sangat berguna untuk lebih memahami data yang sedang dianalisis dan mendapatkan ringkasan dari data tersebut, sehingga data bisa dianalisis dan digunakan dalam pengambilan keputusan (Wagavkar, 2023).

2.1.4 Metode ARIMA

Auto Regressive Integrated Moving Average (ARIMA) adalah sebuah metode analisis statistik yang digunakan untuk memprediksi sebuah nilai di masa depan berdasarkan *time series*. Model ini berdasar pada gagasan bahwa nilai-nilai di masa lampau akan mempengaruhi nilai di masa depan (Prabhakaran, 2023). Model ini bisa digunakan untuk memprediksi data *time series* baik yang stasioner, maupun yang tidak stasioner. Model ini sebenarnya adalah gabungan dari *Auto Regression* (AR), *Differencing* (I), dan *Moving Average* (MA) ("Pengertian ARIMA", 2023). Dalam ARIMA, terdapat 3 parameter untuk menentukan jenis model yang akan digunakan, yaitu p, d, dan q. Parameter p merupakan jumlah lags yang akan dimasukkan dalam model *autoregression*. Parameter d adalah jumlah differencing yang akan diterapkan pada data agar data menjadi stasioner. Sementara parameter q adalah jumlah lags yang akan dimasukkan dalam model *moving average* (Bajaj, 2023).

Beberapa keuntungan dari penggunaan model ARIMA adalah:

1. Model ARIMA adalah model yang efektif untuk mengatasi data yang masih belum stasioner atau masih memiliki trend atau pola
2. Model ARIMA hanya membutuhkan data 1 variabel saja yang terdiri dari data historikal tersebut di masa lampau karena asumsi ARIMA bahwa data di masa lalu berpengaruh terhadap data di masa depan
3. Model ARIMA dapat digunakan untuk melihat tren atau pola yang ada dalam data

Sementara untuk kekurangan dari model ARIMA adalah:

1. Model ARIMA tidak bisa memprediksi nilai ekstrim atau anomali yang ada dalam data
2. Model ARIMA cenderung mengandalkan jumlah data. Semakin besar jumlah data historikal, semakin akurat pula hasilnya.
3. Model ARIMA tidak membedakan antara sebab dan akibat pada suatu kasus

Dengan kelebihan dan kekurangan tersebut, model ARIMA adalah model yang cukup banyak dipakai di berbagai industri ("Pengertian ARIMA", 2023). ARIMA sebenarnya

adalah suatu metode yang cukup fleksibel karena memiliki banyak varian yang ada. ARIMA memiliki beberapa turunan yaitu ARIMAX, SARIMA, dan SARIMAX, dimana ARIMAX adalah ARIMA yang menggunakan variabel independen (faktor X), SARIMA adalah ARIMA yang memiliki seasonality, dan SARIMAX adalah SARIMA dengan faktor X (Prabhakaran, 2023).

2.1.4 Metode *Linear Regression*

Linear Regression adalah sebuah metode prediksi data yang digunakan untuk meramalkan nilai yang tidak diketahui berdasarkan data-data lainnya yang nilainya sudah diketahui. Cara kerja dari linear regression adalah dengan menyusun sebuah grafik garis antara dua variabel data, misalnya x dan y. Variabel x bekerja sebagai variabel independen, dan terletak pada sumbu horizontal. Variabel independen juga disebut variabel eksplanatori atau variabel prediktor. Sementara y bekerja sebagai variabel dependen atau variabel yang diprediksi dan terletak pada sumbu vertikal. Berdasarkan AWS Academy (n.d.), *Linear regression* terdiri dari beberapa jenis yaitu:

1. Regresi linear sederhana

Didefinisikan oleh fungsi:

$$Y = \beta_0 * X + \beta_1 + \epsilon \quad (2.2)$$

2. Regresi linear berganda

Didefinisikan oleh fungsi:

$$Y = \beta_0 * X_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \epsilon \quad (2.3)$$

3. Regresi logistik

Digunakan untuk mengukur kemungkinan sebuah peristiwa menggunakan nilai antara 0 dan 1. Nol mewakili kemungkinan yang tidak mungkin terjadi, sementara 1 mewakili sebaliknya.

Model statistik biasanya memiliki tarik-ulur bawaan dari bias dan varians. Bias merupakan kesalahan yang disebabkan oleh asumsi atau pemikiran yang salah, sementara varians adalah kesalahan yang diakibatkan oleh kepekaan data terhadap *noise*. Varians sering kali berkaitan dengan *overfitting* dan multikolinearitas, karenanya terkadang untuk menyeimbangkan model agar menghasilkan hasil yang baik, perlu dilakukan pengurangan varians melalui proses regularisasi. Regularisasi sendiri adalah proses untuk mengurangi varians, namun dengan menimbulkan bias yang disengaja. Berikut adalah beberapa contoh teknik regularisasi yang paling umum dan sering dipakai (Heeswijk, 2022):

1. Regularisasi LASSO

Regularisasi LASSO (*Least Absolute Shrinkage and Selection Operator*) atau dikenal juga dengan regularisasi L1 adalah teknik regularisasi yang bertujuan untuk memilih variabel independen terkuat dengan menerapkan sebuah penalti absolut. LASSO memiliki keunggulan dalam menangani data dengan variabel independen yang banyak namun kemungkinan memiliki keterkaitan yang kecil. Namun, kelemahannya adalah LASSO hanya memilih 1 variabel dari sekelompok variabel yang saling berkorelasi.

2. Regularisasi Ridge

Regularisasi Ridge atau disebut juga regularisasi L2 adalah teknik regularisasi hampir serupa dengan LASSO, namun alih-alih menerapkan penalti absolut pada rumus, Ridge menerapkan penalti kuadrat. Ridge dapat mengurangi varians secara signifikan dan biasanya baik digunakan untuk data dengan variabel independen yang relatif sedikit. Namun, berbeda dengan LASSO, Ridge tidak membantu dalam *feature selection*.

3. Regularisasi Elastic Net

Regularisasi Elastic Net atau Regularisasi L1 dan L2 adalah teknik regularisasi yang menggabungkan antara LASSO dan Ridge. Teknik ini menggunakan baik penalti absolut maupun penalti kuadrat. Teknik ini bisa membantu dalam *feature selection* dengan mengurangi jumlah *feature* namun di saat yang bersamaan juga menyebarkan penalti secara lebih kuat ke dalam *feature* yang tersisa. Namun, kelemahannya adalah teknik ini juga mewarisi kelemahan dari LASSO dan Ridge.

Keuntungan dari penggunaan *linear regression* adalah ketika sudah tahu bahwa variabel independen dan dependen memiliki hubungan linear, metode ini adalah yang terbaik karena merupakan yang paling kompleks. Sementara untuk kekurangannya sendiri adalah sangat jarang terdapat kasus di dunia nyata yang benar-benar menunjukkan hubungan antara variabel independen dan dependen (Iqbal, 2019).

2.1.5 Normalisasi

Normalisasi adalah teknik yang digunakan untuk mengubah skala data dengan berbagai dimensi menjadi seragam, sehingga menghilangkan perbedaan signifikan antara nilai-nilai. Proses normalisasi berusaha memastikan tidak ada nilai yang terlalu besar atau terlalu kecil, sehingga semua nilai dianggap setara. Ini membuat analisis statistik lebih mudah dan lebih akurat. Normalisasi diperlukan karena dalam satu set data mungkin

terdapat variasi skala pengukuran yang berbeda-beda, sehingga tanpa normalisasi, hasil analisis dapat dipengaruhi oleh variabel dengan skala pengukuran terbesar. Pengaruh ini sangat terasa dalam pengolahan data, terutama pada teknik klusterisasi. Normalisasi data menjadi penting ketika dataset memiliki rentang nilai yang berbeda. Misalnya, jika kolom A memiliki nilai dalam puluhan sementara kolom B memiliki nilai dalam jutaan, perbedaan ini mungkin terlihat sepele tetapi sangat berpengaruh saat melakukan klusterisasi dengan algoritma K-Means. Perhitungan akan lebih berfokus pada kolom B yang memiliki nilai lebih besar, sehingga kolom A dan kolom lainnya yang digunakan dalam perhitungan tidak akan memberikan pengaruh yang signifikan. Akibatnya, hasil analisis bisa jadi tidak sesuai dengan yang diinginkan (Pradistya, 2022).

Beberapa contoh dari metode normalisasi adalah normalisasi *min-max*, *z-score*, dan *max absolute*. Berikut adalah penjelasan dari ketiga metode tersebut:

1. Normalisasi *Z-score*, juga dikenal sebagai standarisasi, adalah teknik di mana nilai pada atribut dinormalisasi berdasarkan nilai rata-rata (*mean*) dan standar deviasi. Inti dari teknik ini adalah mentransformasikan nilai data ke skala umum di mana nilai rata-rata adalah nol dan standar deviasi adalah satu. Berikut adalah rumus untuk normalisasi *Z-score*:

$$X' = \frac{(X - \mu)}{\sigma} \quad (2.4)$$

di mana X adalah nilai asli, μ adalah rata-rata data, dan σ adalah standar deviasi data. Normalisasi *Z-score* dalam *data mining* bermanfaat untuk menganalisis data yang memerlukan perbandingan nilai dengan nilai rata-rata (Trivusi, 2022).

2. Normalisasi *min-max*, metode normalisasi ini mengubah sebuah kumpulan data menjadi skala mulai dari 0 (min) hingga 1 (max). Data asli mengalami modifikasi linear dalam prosedur normalisasi data ini. Nilai minimum dan maksimum dari data diambil, dan setiap nilai diubah menggunakan rumus di bawah ini:

$$X' = \frac{(X - \min(x))}{(\max(x) - \min(x))} (new_{\max(x)} - new_{\min(x)}) + new_{\min(x)} \quad (2.5)$$

Dimana X adalah nilai asli dan X' adalah hasil setelah normalisasi (Trivusi, 2022).

3. Normalisasi *max absolute*, metode ini mengubah data berdasarkan nilai absolut maksimum dari setiap fitur. Dalam metode ini, nilai absolut maksimum di seluruh fitur ditentukan, dan setiap nilai dibagi dengan nilai absolut maksimum tersebut. Nilai yang dihasilkan akan berada di antara -1 dan 1. Rumus untuk metode ini adalah:

$$X' = \frac{(X)}{abs_max(x)} \quad (2.6)$$

Dimana X adalah nilai asli dan $abs_max(x)$ adalah nilai absolut dari nilai maks seluruh X (Realm, 2023).

2.2 Tinjauan Studi

Pada bagian ini, penelitian-penelitian sebelumnya yang menjadi penunjang bagi skripsi ini akan dijabarkan.

2.2.1 *Forecasting Salaries and Wages using Auto Regressive Integrated Moving Average (ARIMA) Algorithm (Toledo, 2022)*

Gaji merupakan aspek yang sangat penting dalam memotivasi karyawan agar menghasilkan kinerja yang baik. Tidak hanya itu, gaji juga sangat penting untuk keberlangsungan hidup seseorang atau bahkan suatu keluarga. Meningkatkan kinerja karyawan berarti juga meningkatkan kinerja organisasi tersebut. Di Filipina, pertambangan memegang peranan penting dalam pengembangan industri di negara tersebut, terutama di wilayah Caraga, Mindanao. Beberapa teknik sudah digunakan untuk memodelkan dan membuat sistem prediksi gaji seperti teknik-teknik *data mining* dan *regression*. Namun, metode-metode tersebut menghadapi suatu masalah yaitu sulitnya untuk menggabungkan hasil-hasil dari metode tersebut ke latar belakang statistika. Karena itu, penelitian ini akan menggunakan metode *time series* yang terkenal yaitu ARIMA untuk melakukan prediksi gaji karyawan di perusahaan tambang tertentu di Mindanao, Filipina.

Penelitian ini akan menggunakan dataset berupa data gaji karyawan di beberapa perusahaan tambang yang sudah dipilih mulai dari tahun 2014 hingga 2018. Proses pada metode ARIMA akan dimulai dari *data processing* dan *zero transform processing*, sebelum data di *smoothing* hingga *stationary* dan dikenali polanya. Kemudian, parameter p, d, dan q akan ditentukan untuk setelahnya dibuat model akhirnya dan dilakukan prediksi. Hasil prediksi akan dilakukan *reduction* untuk memperoleh hasil akhir yang sesungguhnya. Parameter yang digunakan dalam penelitian ini adalah (1, 0, 1) dan simulasi modelnya dilakukan dengan menggunakan aplikasi perangkat lunak GRET. Jangka waktu gaji yang akan diprediksi pada penelitian ini adalah untuk data 5 tahun ke depan yang berarti tahun 2019-2023. Hasil dari penelitian ini adalah sebuah model prediksi gaji untuk 5 tahun ke depan, dimana data tahun 2018-2021 menunjukkan tren kenaikan, sementara tahun 2023-2023 memiliki tren yang stabil.

Kelebihan dari penelitian ini adalah penelitian ini berhasil memperoleh sebuah model prediksi menggunakan metode *time series* ARIMA. Dari penelitian ini pula bisa dilihat bahwa ARIMA adalah metode yang cocok digunakan untuk melakukan prediksi jangka pendek karena pada jangka panjang ARIMA akan mencapai suatu tren yang stabil. Untuk kekurangan dari penelitian ini adalah penelitian ini hanya menggunakan 1 variabel yaitu variabel gaji dalam pemodelannya, tanpa mempertimbangkan bahwa mungkin setiap individu akan memperoleh gaji yang berbeda karena dipengaruhi oleh berbagai faktor. Mengambil kesimpulan dari penelitian Toledo, skripsi ini akan menggunakan metode ARIMA untuk melakukan prediksi jangka pendek pada UMR dan inflasi Indonesia. Sementara untuk prediksi gajinya sendiri, skripsi ini akan menggunakan metode regresi linear dan menggunakan beberapa variabel independen sebagai faktor yang mungkin mempengaruhi gaji setiap individu.

2.2.2 Prediksi Gaji Berdasarkan Pengalaman Bekerja Menggunakan Metode Regresi Linear (Saputra et al., 2022)

Hampir sebagian besar industri pasti tidak bisa lepas dari sumber daya manusia (SDM) di dalamnya. Meski sekarang industri sudah banyak digitalisasi dengan berbagai teknologi modern yang ada, peran SDM masih sangat penting untuk kemajuan suatu perusahaan, apalagi untuk bersaing di tengah pasar yang sangat modern saat ini. Karena itu, sangat penting bagi suatu perusahaan untuk meningkatkan antusias pekerjanya dalam bekerja sehingga bisa menghasilkan hasil yang optimal dan memuaskan. Salah satu cara yang bisa dilakukan adalah dengan memperhatikan gaji setiap karyawannya. Bukan asal memberikan gaji yang tinggi, yang penting dalam suatu perusahaan adalah memberikan gaji yang sesuai kepada setiap karyawannya. Kesesuaian gaji bisa diukur dari jabatan dan pengalaman kerja karyawan tersebut.

Berangkat dari masalah tersebut, penelitian ini ingin membuat sistem untuk memprediksi gaji karyawan yang sesuai berdasarkan pengalaman kerja karyawan tersebut. Dataset yang akan digunakan adalah dataset hasil survei google form yang disebar pada narasumber yang *valid*, terdiri dari kolom nama, pengalaman kerja, dan gaji, dengan jumlah 30 data. Pemodelan akan dilakukan menggunakan metode regresi linear dengan pengalaman kerja sebagai variabel independen dan gaji karyawan sebagai variabel dependen-nya. Selain dilakukan percobaan prediksi dengan inputan tertentu, juga dilakukan pengujian tingkat keakuratan dan *error* menggunakan *mean absolute error* (MAE). Hasil yang didapatkan dari penelitian ini adalah model persamaan regresi linear dan

MAE dari metode tersebut pada kasus di penelitian ini. Didapatkan MAE dengan angka 2,051033333.

Kelebihan dari penelitian ini adalah penelitian ini memperhitungkan adanya faktor eksternal dalam prediksi yang dilakukannya yaitu pengalaman kerja. Selain itu, penelitian ini tidak menggunakan *library* apapun dan menghitung semuanya secara manual sehingga prosesnya sangat jelas dan transparan. Namun, kekurangan dari penelitian ini adalah datasetnya yang berjumlah sangat sedikit, yaitu 30 data. Tidak hanya itu, seperti yang disebutkan di latar belakang bahwa jabatan atau jenis pekerjaan juga akan sangat mempengaruhi gaji yang diterima oleh karyawan, namun penelitian ini tidak menggunakan variabel independen tersebut. Untuk melengkapi kekurangan yang ada pada penelitian ini, skripsi ini akan menggunakan metode regresi linear yang lebih kompleks dengan beberapa input yang bisa mengkategorikan dataset yang akan dipakai, misalnya jika *user* input jenis pekerjaan A, maka hanya dataset dengan pekerjaan A saja yang akan digunakan dalam *data training*. Selain itu, dataset yang digunakan akan lebih banyak dengan setidaknya 1500 data histori gaji lulusan mahasiswa Universitas Kristen Petra.

2.2.3 A linear regression approach to predicting salaries with visualizations of job vacancies: a case study of Jobstreet Malaysia (Samah et al., 2022)

Di era yang sudah terdigitalisasi ini, banyak sekali orang yang mencari pekerjaan melalui internet. Salah satu *platform* pencari pekerjaan yang paling populer di Malaysia adalah Jobstreet. Informasi pekerjaan di Jobstreet memiliki beberapa atribut seperti gaji, posisi, jenis pekerjaan, deskripsi, dan lokasi. Namun, hanya sedikit sekali informasi yang berkaitan dengan gaji yang ditawarkan, *scope* pekerjaan, dan *requirement* yang dibutuhkan untuk pekerjaan tersebut. Kebanyakan gaji untuk lowongan pekerjaan adalah gaji berdasarkan tren gaji saat itu, namun sayangnya Jobstreet sendiri masih memiliki informasi yang terbatas untuk gaji yang ditawarkan sehingga tren gaji saat itu pun belum tentu *valid*. Selain itu, pencari pekerjaan juga mengalami kesulitan untuk membandingkan dan memilih dengan banyaknya tawaran yang ada di Jobstreet. Penelitian ini ingin merancang sebuah aplikasi berbasis web dengan bahasa pemrograman Python untuk memvisualisasikan data-data secara ringkas kepada para pencari pekerjaan untuk memudahkan mereka dalam menganalisis pekerjaan yang diinginkan, dimana salah satunya adalah membandingkan gaji yang ditawarkan berdasarkan data pribadi pencari pekerja tersebut.

Metode yang digunakan pada penelitian ini adalah metode regresi linear untuk memprediksi gaji yang sesuai untuk seseorang berdasarkan jenis pekerjaan yang dipilih dan

pengalaman kerja yang dimiliki orang tersebut. Pengalaman kerja akan berperan sebagai variabel independen sementara gaji sebagai variabel dependen. Dataset yang digunakan untuk melakukan prediksi adalah data hasil *scraping* dari situs Jobstreet itu sendiri. Namun, Sebelum dilakukan prediksi, akan dilakukan validasi metode dengan membagi data 80% untuk *training* dan 20% untuk *testing* untuk kemudian divisualisasikan dan dihitung *mean absolute error* (MAE) dari metode tersebut. Hasil dari penelitian ini adalah MAE untuk setiap jenis pekerjaan yang ada di Jobstreet yang bervariasi mulai dari 424 hingga 2306. Selain itu, sistem visualisasi pekerjaan dan prediksi gaji pun berhasil dibuat dengan hasil *system usability scale* (SUS) mencapai angka 96,58%.

Kelebihan dari penelitian ini adalah penggunaan regresi linear untuk memprediksi gaji sudah sangat baik dan kompleks. Hal itu membuat hasil yang dihasilkan diharapkan bisa lebih akurat dibandingkan pada penelitian Saputra et al. Selain itu, penelitian ini juga melakukan pengecekan *error* dan menghasilkan visualisasi yang bagus. Namun, untuk kekurangan dari penelitian ini sendiri, penelitian ini mengandalkan data dari *scraping* situs Jobstreet dalam kerjanya. Padahal, seperti yang dikatakan data gaji di Jobstreet sendiri masih kurang *valid* dan banyak yang membuka lowongan tanpa memberikan tawaran gaji. Perlu digaris bawahi bahwa standar gaji dari waktu ke waktu akan terus naik, sementara jika tren gaji di Jobstreet tidak naik, maka prediksi pun juga tidak akan naik. Untuk mengatasi kekurangan dari metode ini, skripsi ini akan menggunakan data UMR dan inflasi yang memiliki trend naik dari waktu ke waktu. Data UMR dan inflasi ini akan diprediksi nilainya di masa depan, untuk dijadikan salah satu variabel independen dalam prediksi menggunakan regresi linear sehingga hasil prediksi gaji pun juga akan mengalami kenaikan tren.

2.2.4 Improving Students' Motivation to Study using Salary Prediction System (Khongchai & Songmuang, 2016)

Di era modern ini, banyak anak masuk ke jenjang perkuliahan tanpa mengetahui apa tujuan akhir mereka. Akibatnya, banyak anak tidak termotivasi saat berkuliah dan hanya berkuliah asal-asalan saja tanpa adanya pengetahuan baru yang masuk. Kebanyakan anak memasuki jenjang perkuliahan dengan angan-angan akan mendapatkan pekerjaan bergaji tinggi setelah mereka lulus nanti. Selain itu, bisa hidup nyaman dengan gaji tinggi merupakan mimpi dari sebagian besar orang di muka bumi ini. Cara paling realistis untuk memberikan informasi gaji kepada mahasiswa adalah dengan berdasarkan data yang sudah ada dari mahasiswa yang sudah lulus sebelumnya. Karena itu, penelitian ini ingin

menggunakan gaji prediksi yang didapat dari histori mahasiswa yang sudah lulus untuk memotivasi mahasiswa belajar dengan lebih giat.

Metode yang akan digunakan dalam penelitian ini adalah metode *data mining*, *decision tree*. Dataset yang akan digunakan adalah data mahasiswa yang sudah lulus selama 10 tahun pada tahun 2006-2015 Rajamangala University of Technology Thanyaburi, Thailand. Data-data tersebut termasuk jenis kelamin, program, tipe tempat kerja, pengalaman, sertifikasi, ipk, gaji, alamat, dan lain-lain. Nantinya, mahasiswa yang ingin menggunakan sistem ini akan memasukkan data-data mereka di kolom yang sudah disediakan, terdiri dari jenis kelamin, fakultas, program, tipe pekerjaan, pelatihan pekerjaan, sertifikasi, dan IPK. Dari informasi-informasi yang dimasukkan oleh mahasiswa tersebut, sebuah modal akan dibuat dan hasil prediksi untuk gaji akan didapat. Hasil dari penelitian ini adalah keakuratan sistem yang mencapai angka 41,39%. Selain itu, berdasarkan kuisisioner yang disebar untuk mengevaluasi keefektifan sistem dihasilkan bahwa sistem ini bisa meningkatkan motivasi belajar mahasiswa dan menunjukkan sudut pandang positif untuk masa depan mereka.

Kelebihan dari penelitian ini adalah peneliti menggunakan variabel-variabel eksternal yang sangat dekat dengan mahasiswa itu sendiri yaitu dari mahasiswa yang sudah lulus (alumni) universitas mahasiswa. Selain itu, variabel yang digunakan juga banyak, mendetail, dan spesifik sehingga hasil yang dihasilkan bisa lebih akurat. Namun, untuk kekurangan dari penelitian ini adalah hasil yang dihasilkan kurang spesifik kemungkinan besar karena metode *decision tree* yang digunakan. Jadi, hasil dari prediksi hanya menunjukkan prediksi gaji < angka tertentu atau > angka tertentu. Selain itu, input IPK pun juga menggunakan pengkategorian seperti itu yaitu < atau > angka tertentu. Dengan begitu, meski hasil yang dihasilkan cukup akurat namun kurang spesifik. Untuk mengatasi kekurangan tersebut, pada skripsi ini, akan menggunakan metode regresi linear untuk memodelkan hubungan secara linear sehingga input yang dimasukkan oleh *user* nantinya tidak akan dikategorikan. *User* bisa memasukkan berapapun IPK / SKKK mereka. Selain itu, hasil yang dikeluarkan oleh sistem prediksi juga akan bisa lebih spesifik.

2.2.5 *Salary Prediction for Computer Engineering Positions in India* (Saeed, Abdulah, & Tahir, 2023)

Selama 20 tahun terakhir, Teknologi Informasi di India adalah salah satu sektor yang berkembang dengan sangat pesat. Karena hal tersebut, jurusan Teknologi Informasi juga menjadi jurusan yang sangat populer karena potensi gaji dan pekerjaan yang bisa

didapat setelah lulus. Gaji awal bagi lulusan baru sangat penting sebagai indikator prospek finansial dan status profesional mereka di masa depan. Gaji awal dapat mempengaruhi peningkatan gaji dan manfaat akuisisi di masa depan. Dengan itu, merupakan sesuatu yang cukup penting untuk mengetahui atau memprediksi gaji awal seorang lulusan Teknologi Informasi di pasar tenaga kerja India. Namun perlu diingat juga bahwa ada banyak sekali faktor-faktor yang bisa mempengaruhi gaji awal seseorang. Penelitian ini akan melihat bagaimana faktor-faktor seperti demografi, performa akademi, kepribadian, dan hasil ujian akan mempengaruhi gaji awal seseorang.

Dataset yang akan digunakan adalah data *Aspiring Minds' Employment Outcomes* (AMEO) pada tahun 2015. Dataset tersebut berjumlah 2002 data dan terdiri dari 11 variabel yang terdiri dari gaji, lama bekerja, posisi, kota, jenis kelamin, dan lain-lain. Penelitian ini akan menggunakan metode pembelajaran mesin, seperti Naive Bayes, *Random Forest*, dan SVM, untuk melakukan analisis regresi dan memprediksi gaji awal lulusan teknik di pasar tenaga kerja India. Setelah menghilangkan beberapa *outlier* yang ada pada data, data menunjukkan hasil yang positif untuk hubungan antara IPK kuliah dan gaji. Hasil dari penelitian ini menunjukkan bahwa variabel-variabel seperti latar belakang pendidikan, riwayat pekerjaan, sertifikasi, pengalaman manajemen, kompetensi kerja, dan lingkungan kerja berhubungan dengan perubahan gaji yang akan terjadi, sementara faktor seperti gelar kuliah dan pengalaman kerja akan sangat mempengaruhi dalam gaji awal. Untuk ketiga metode yang digunakan dalam penelitian, ditemukan bahwa Naïve Bayes menghasilkan *Root Mean Squared Error* (RMSE) terkecil yaitu 0,305 dengan tingkat keakuratan 41,11%.

Kelebihan dari penelitian ini yaitu penggunaan dari 3 metode *machine learning* sehingga bisa mencari metode yang terbaik dan penggunaan variabel yang cukup banyak sehingga diharapkan hasilnya bisa lebih akurat. Sementara kekurangan dari penelitian ini adalah penelitian ini menggunakan data mahasiswa Teknologi Informatika secara keseluruhan tanpa mempertimbangkan bahwa setiap universitas memiliki standard yang berbeda-beda. Misalnya saja, IPK 3.5 dari universitas dengan akreditasi A tentu saja tidak bisa dibandingkan dengan IPK 3.5 dari universitas dengan akreditasi C. Untuk mengatasi kekurangan dari penelitian ini, skripsi ini hanya akan menggunakan data dari mahasiswa Universitas Kristen Petra dataset untuk melihat hubungan antara performa akademis perkuliahan dengan gaji.